

# Optymalizacja układu turbin w elektrowniach wiatrowych z zastosowaniem algorytmów genetycznych

Paweł Małecki

14.06.2024

## 1 Wstęp

W farmach wiatrowych turbiny są rozmieszczone blisko siebie ze względów ekonomicznych związanych z wykorzystaniem ziemi oraz infrastrukturą, taką jak drogi dojazdowe i linie przesyłowe. Jednakże ta bliskość powoduje, że turbiny są dotknięte przez efekt wake, w którym turbulencje i zmniejszona prędkość wiatru za turbiną wiatrową wpływają negatywnie na produkcję energii turbin znajdujących się w strefie cienia aerodynamicznego. Turbulencje te mogą powodować straty energii na farmach wiatrowych sięgające 10-20%.

Badania sugerują, że proste układy prowadzą do nieoptymalnej wydajności, zwłaszcza w dużych farmach wiatrowych z setkami lub tysiącami turbin. W związku z tym istnieje potrzeba stosowania metod optymalizacyjnych, które uwzględniają zarówno minimalizację efektu wake, jak i maksymalizację produkcji energii, przy jednoczesnym spełnieniu ograniczeń przestrzennych.

## 2 Model efektu wake i rocznej produkcji energii

### 2.1 Model Jensena

Model Jensena jest jednym z najczęściej stosowanych modeli do opisu efektu wake w farmach wiatrowych. Model ten zakłada, że prędkość wiatru za turbiną maleje wzdłuż osi strugi wake, a obszar wake rozszerza się stożkowo. Wzór opisujący prędkość wiatru za turbiną  $i$  pod wpływem turbiny  $j$  jest następujący:

$$u_{ij} = u_0 \left( 1 - \frac{2}{3} \left( \frac{r_r}{r + \alpha x} \right)^2 \right) \quad (1)$$

gdzie  $\alpha$  to współczynnik napływu zależny m.in. od wysokości wieży turbiny wiatrowej. Dla uproszczenia można przyjąć  $\alpha = 0.1$ .

Prędkość wiatru przepływającego przez  $i$ -tą turbinę dla  $N$  turbin znajdujących się przed nią można opisać następującym równaniem:

$$u_i = u_0 \left( 1 - \sqrt{\sum_{j=1}^N \left( 1 - \frac{u_{ij}}{u_0} \right)^2} \right) \quad (2)$$

gdzie:

- $u_i$  - prędkość wiatru przepływającego przez  $i$ -tą turbinę (w m/s),
- $u_0$  - prędkość wiatru przed turbinami (w m/s),
- $u_{ij}$  - prędkość wiatru za turbiną  $j$  wpływająca na turbinę  $i$  (w m/s),
- $N$  - liczba turbin znajdujących się przed turbiną  $i$ .

## 2.2 Charakterystyka mocy turbiny

Moc generowana przez  $i$ -tą turbinę wiatrową przy prędkości wiatru  $v_i$  jest określana na podstawie charakterystyki mocy turbiny, która zazwyczaj jest podana jako funkcja prędkości wiatru. Najczęściej używana formuła na moc  $P$  w zależności od prędkości wiatru  $v$  jest następująca:

$$P_i(v_i) = \begin{cases} 0, & \text{if } v < v_{ci} \text{ or } v > v_{co} \\ P_{\text{rated}} \left( \frac{v - v_{ci}}{v_r - v_{ci}} \right)^3, & \text{if } v_{ci} \leq v < v_r \\ P_r, & \text{if } v_r \leq v < v_{co} \end{cases} \quad (3)$$

gdzie:

- $P_i(v_i)$  - wyjście mocy  $i$ -tej turbiny dla prędkości  $v_i$ ,
- $P_{\text{rated}}$  - moc znamionowa turbiny (w MW),
- $v_{ci}$  - prędkość wiatru do uruchomienia (w m/s),
- $v_r$  - znamionowa prędkość wiatru (w m/s),
- $v_{co}$  - prędkość wiatru do wyłączenia (w m/s).

## 2.3 Roczna Produkcja Energii (AEP)

Roczna produkcja energii (Annual Energy Production, AEP) jest kluczowym wskaźnikiem efektywności farmy wiatrowej. AEP można obliczyć, integrując moc generowaną przez turbiny wiatrowe w ciągu roku, uwzględniając zmienność prędkości wiatru i efekt wake. Formuła na  $AEP_{\text{total}}(\mathbf{X})$  całkowitą roczną energię farmy wyrażoną w MWh jest następująca:

$$AEP_{\text{total}}(\mathbf{X}) = \sum_{i=1}^N AEP_i(\mathbf{X}) = \sum_{i=1}^N \int_0^{360^\circ} \int_0^{u_{\max}} [P_i(u_i, u_0, \theta) \cdot p(u_0, \theta) \cdot 8760] du_0 d\theta \quad (4)$$

gdzie:

- $\mathbf{X}$  wektor pozycji turbin,
- $N$  liczba turbin wiatrowych,
- $AEP_i(\mathbf{X})$  roczna energia dla  $i$ -tej turbiny wyrażona w MWh,
- $u_i$  prędkość wiatru dla  $i$ -tej turbiny uwzględniająca efekt wake opisany w sekcji 2.1,
- $\theta$  kierunek wiatru,
- $P_i(u_i, u_0, \theta)$  moc wyjściowa dla  $i$ -tej turbiny jako funkcja  $u_i$ ,  $u_0$  i  $\theta$ ,
- $p(u_0, \theta)$  to funkcja gęstości prawdopodobieństwa dla  $u_0$  i  $\theta$ ,
- $u_{\max}(\mathbf{X})$  to maksymalna prędkość wiatru, którą wpływają turbiny, zależna od układu i efektów wake.

Funkcja gęstości prawdopodobieństwa  $p(u_0, \theta)$  dla prędkości wiatru  $u_0$  i kierunku  $\theta$  opiera się na róży wiatru, czyli reprezentacji rozkładu prędkości i kierunków wiatru dla danej lokalizacji. Pozwala na uwzględnienie dominujących kierunków wiatru oraz częstotliwości ich występowania.

### 3 Ograniczenia minimalizacji

Zmienne  $t_i = (x_i, y_i)$  oznaczające pozycję  $i$ -tej turbiny, są ograniczone do przedziału  $[0, L]$ , czyli kwadratowego obszaru dopuszczalnego:

$$x_i, y_i \in [0, L], \quad i = 1, 2, \dots, N$$

Minimalna odległość między każdą parą turbin jest określona jako  $D$ :

$$\|t_i - t_j\| \geq D \quad \text{dla } i, j = 1, 2, \dots, N, \quad i \neq j$$

gdzie:

- $N$  jest liczbą turbin,
- $\|\mathbf{r}_i - \mathbf{r}_j\|$  oznacza odległość euklidesową między turbinami  $i$  i  $j$ .

### 4 Funkcja celu

Funkcja celu dla maksymalizacji produkcji energii układu turbin w farmie wiatrowej opiera się na rocznej produkcji energii (AEP).

$$AEP_{\text{total}}(\mathbf{X}) = \sum_{i=1}^N AEP_i(\mathbf{X}) \quad (5)$$

Rozważane były również modyfikację funkcji celu o dodanie do funkcji kar w dwóch wariantach.

$$AEP_{\text{total}}(\mathbf{X}) = \sum_{i=1}^N AEP_i(\mathbf{X}) - \text{boundaryPenalty}(\mathbf{X}) - \text{spacingPenalty}(\mathbf{X}) \quad (6)$$

oraz

$$AEP_{\text{total}}(\mathbf{X}) = \sum_{i=1}^N AEP_i(\mathbf{X}) \times \text{isLayoutValid}(\mathbf{X}) \quad (7)$$

gdzie:

- $\text{boundaryPenalty}(\mathbf{X})$  funkcja kary zwracająca ilość niepoprawnych pozycji turbin wychodzących poza dopuszczany obszar układu przemnożoną przez pewien skalar.
- $\text{spacingPenalty}(\mathbf{X})$  funkcja kary oblicza sumę kwadratów różnicy pomiędzy minimalną dopuszczalną odległością  $D$  między każdą parą turbin, a rzeczywistą odległością między tymi turbinami w danym rozmieszczeniu  $\mathbf{X}$ . Im mniejsza odległość niż minimalna, tym większa kara. Kwadraty odległości liczone dla  $\|t_i - t_j\| < D$  w przeciwnym wypadku 0.
- $\text{isLayoutValid}(\mathbf{X})$  funkcja kary weryfikująca poprawność układu turbin zwracająca 1 dla poprawnego układu 0 lub 0.5.

## 5 Dane do problemu

Dane uproszczone z farmy wiatrowej w Kostomłotach znajduje się w województwie dolnośląskim, w południowej Polsce. Róża wiatru dla tego obszaru została przedstawiona na rysunku 1. Charakterystyka mocy turbin znajduje się na rysunku 2.

- Liczba turbin: 9
- Powierzchnia obszaru:  $2100m \times 2100m$
- Minimalna odległość między turbinami: 300 m
- Prędkość wiatru: 9.8 m/s
- Kierunek wiatru:  $300.0^\circ$
- Wysokość gondoli: 122 m
- Średnica łopat wiatraka: 136 m
- Turbiny wiatrowe: Vestas V136
  - Moc nominalna: 3 MW
  - Prędkość włączania: 3.0 m/s
  - Prędkość wyłączania: 22.5 m/s




Figure 1: Róża wiatru dla obszaru FW Kostomłoty




Figure 2: Przybliżona charakterystyka mocy turbin Vestas V136

## 6 Przedstawienie zamodelowanego środowiska

Na rysunku 3 przedstawiono mapę wpływu efektu wake na prędkość wiatru dla różnych kierunków wiatru.

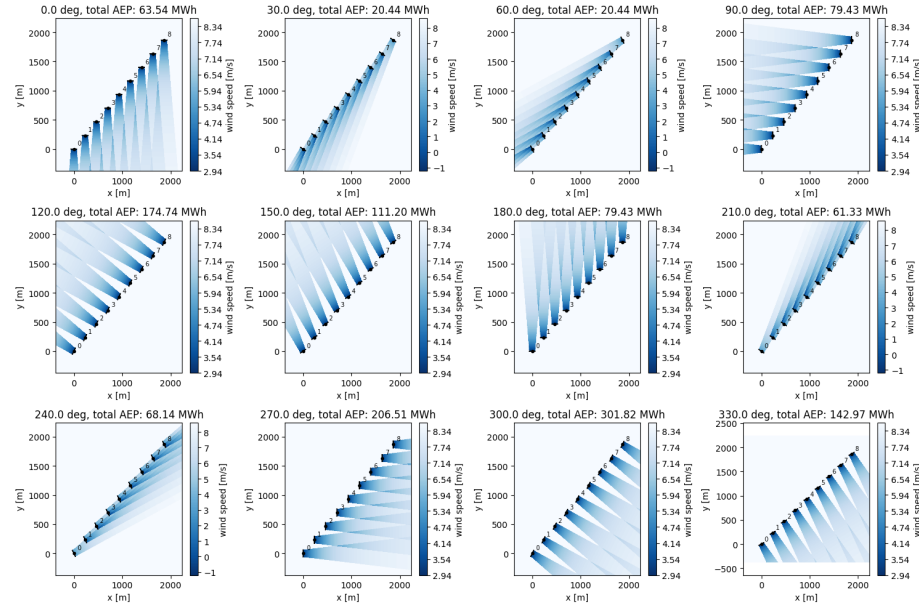


Figure 3: Mapa efektu wake dla różnych kierunków wiatru

## 7 Rozwiązanie za pomocą metody Powell'a

Dla losowego początkowego układu turbin metoda Powell'a uzyskała poprawne rozwiązania w 20% z 10 wykonanych symulacji (poprawne układy turbin). Maksymalna moc rocznej produkcji energii (AEP) dla poprawnego układu wyniosła 276.924 MWh.

## 8 Rozwiązanie za pomocą algorytmów genetycznych

Dla zastosowania algorytmu genetycznego z wielkością populacji początkowej 100 osobników, 50 generacji, 4 osobnikach uczestniczących w krzyżowaniu metodą dwupunktową, z selekcją typu Stochastic universal sampling (SUS), operatorem mutacji swap z prawdopodobieństwem 20% uzyskujemy rozwiązanie, którego maksymalna moc rocznej produkcji energii (AEP) dla poprawnego układu wyniosła 301.816 MWh. Finalny układ turbin znajduje się na na rysunku 4.

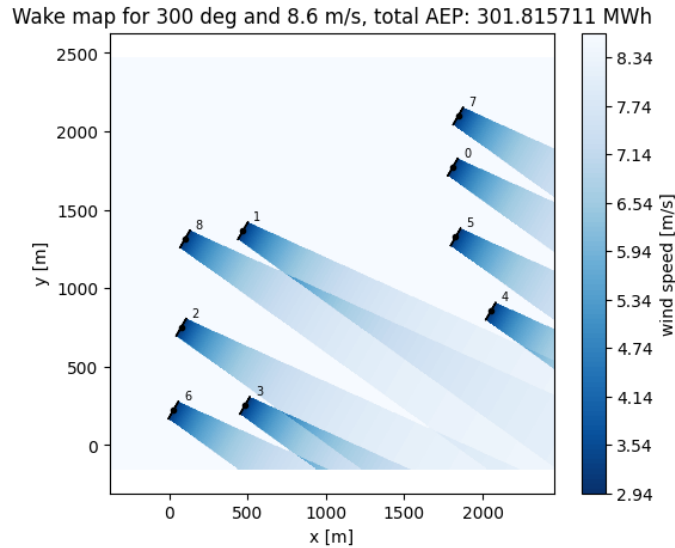


Figure 4: Wynikowy najlepszy układ turbin pochodzący z algorytmu genetycznego

## 9 Wnioski

Metoda Powell'a jest efektywna w przypadku prostych problemów optymalizacyjnych, jednak może napotykać trudności w bardziej złożonych układach. Jednak przy większej ilości iteracji osiągnęła poprawne rozwiązania. Możemy zaobserwować, że głównym czynnikiem decydującym o jakości uzyskanego rozwiązania i jego poprawności jest początkowo wylosowany układ turbin.

Zastosowanie algorytmów genetycznych okazało się skuteczne w znalezieniu bardziej optymalnych rozwiązań w porównaniu do metody Powell'a.

Algorytmy genetyczne są skutecznymi narzędziami do rozwiązywania problemów optymalizacyjnych, zwłaszcza w przypadkach, gdzie przestrzeń poszukiwań jest duża i funkcja celu może mieć wiele lokalnych optimum. Dzięki swojej naturze ewolucyjnej, algorytmy genetyczne są dobrze przystosowane do znajdowania rozwiązań zbliżonych do optymalnych, nawet w przypadku funkcji celu, które nie są różniczkowalne posiadają wiele lokalnych ekstremów.

Podsumowując, algorytmy genetyczne stanowią potężne narzędzie do rozwiązywania złożonych problemów optymalizacyjnych, oferując równowagę między eksploracją i eksploatacją przestrzeni poszukiwań, co prowadzi do efektywnego znalezienia najlepszych rozwiązań dla zadanego problemu.

## References

- [1] Adam Słowik, Halina Kwaśnicka, *Evolutionary algorithms and their applications to engineering problems*, 2020.
- [2] David E. Goldberg, *Algorytmy genetyczne i ich zastosowania*.
- [3] Jarosław Arabas, *Wykłady z algorytmów ewolucyjnych*.
- [4] Zbigniew Michalewicz, David B. Fogel, *Jak to rozwiązać, czyli nowoczesna heurystyka*.
- [5] Naima, Charhouni, Sallaou, Mohammed, Mansouri, Khalifa, *Realistic wind farm design layout optimization with different wind turbines types*, 2019.
- [6] Polenergia, *FW Kostomłoty*, [www.polenergia.pl/nasze-aktywa/wytwarzanie/ladowe-farmy-wiatrowe/fw-kostomloty/](http://www.polenergia.pl/nasze-aktywa/wytwarzanie/ladowe-farmy-wiatrowe/fw-kostomloty/).
- [7] Energy Fundamentals, *Offshore wind farm layout optimization: What is the hype?*, [www.energy-fundamentals.org/15.htm](http://www.energy-fundamentals.org/15.htm).
- [8] Maldonado-Correa, J. et al., *Analysis of the Annual Energy Production of the Villonaco Wind Farm*, 2023.
- [9] Vattenfall Group, *Mathematics generate million euro savings on future offshore wind farms*, [group.vattenfall.com/press-and-media/newsroom/2019/mathematics-generate-million-euro-savings-on-future-offshore-wind-farms](http://group.vattenfall.com/press-and-media/newsroom/2019/mathematics-generate-million-euro-savings-on-future-offshore-wind-farms).
- [10] Synapse Energy, *Wind farm wake effects are real: we should plan them*, [www.synapse-energy.com/offshore-wind-wake-effects-are-real-we-should-plan-them](http://www.synapse-energy.com/offshore-wind-wake-effects-are-real-we-should-plan-them).
- [11] MIT News, *Wind farm optimization: Energy flow*, [news.mit.edu/2022/wind-farm-optimization-energy-flow-0811](http://news.mit.edu/2022/wind-farm-optimization-energy-flow-0811).
- [12] Neural Designer, *Genetic algorithms for feature selection*, [https://www.neuraldesigner.com/blog/genetic\\_algorithms\\_for\\_feature\\_selection/](https://www.neuraldesigner.com/blog/genetic_algorithms_for_feature_selection/).
- [13] Towards Data Science, *Introduction to genetic algorithms including example code*, <https://towardsdatascience.com/introduction-to-genetic-algorithms-including-example-code-e396e98d8bf3>.